

Technical Report

Oleh: Najla Tsabita Afiyah

1. EDA

1.1. Overview dan Karakteristik Dataset

Dataset train.csv memiliki 39073 baris dan 15 kolom, yang mencakup 6 kolom numerik bertipe int64 dan 9 kolom kategorikal bertipe object.

	age	workclass	fnlwgt	education	education-num	marital-status	occupation	relationship	race	sex	capital-gain	capital-loss	hours-per-week	native-country	income
0	37	Private	193106	Bachelors	13	Never-married	Sales	Not-in-family	White	Female	0	0	30	United-States	<=50K.
1	56	Self-emp-inc	216636	12th	8	Married-civ-spouse	Exec-managerial	Husband	White	Male	0	1651	40	United-States	<=50K
2	53	Private	126977	HS-grad	9	Separated	Craft-repair	Not-in-family	White	Male	0	0	35	United-States	<=50K
3	72	Private	205343	11th	7	Widowed	Adm-clerical	Unmarried	White	Female	0	0	40	United-States	<=50K
4	46	State-gov	106705	Masters	14	Never-married	Exec-managerial	Not-in-family	White	Female	0	0	38	United-States	<=50K

Statistik data:

	age	fnlwgt	education-num	capital-gain	capital-loss	hours-per-week
count	39073.000000	3.907300e+04	39073.000000	39073.000000	39073.000000	39073.000000
mean	38.643488	1.899922e+05	10.069844	1038.040540	86.807949	40.476877
std	13.685634	1.054768e+05	2.574387	7204.953114	401.276773	12.401251
min	17.000000	1.376900e+04	1.000000	0.000000	0.000000	1.000000
25%	28.000000	1.177670e+05	9.000000	0.000000	0.000000	40.000000
50%	37.000000	1.786150e+05	10.000000	0.000000	0.000000	40.000000
75%	48.000000	2.383290e+05	12.000000	0.000000	0.000000	45.000000
max	90.000000	1.490400e+06	16.000000	99999.000000	4356.000000	99.000000

1.2. Kualitas Data

Dalam pemeriksaan kualitas data ditemukan beberapa isu yang harus ditangani:


- 1) Ditemukan *missing values* pada tiga kolom kategorikal utama: workclass (769 data null), occupation (771 data null), dan native-country (222 data null).
- 2) Selain nilai Null, terdapat data kosong tak terstruktur berbentuk '?' pada: workclass (1464 data), occupation (1470 data), dan native-country (466 data).
- 3) Terdapat inkonsistensi pada kolom target income pada awalnya terbagi menjadi empat variasi string: "<=50K", "<=50K.", ">50K", dan ">50K.". Pada kolom ini dilakukan pembersihan dan standarisasi biner menjadi:



- 0 ($\leq 50K$): 29724 baris
- 1 ($> 50K$): 9349 baris

1.3. Analisa Fitur Numerik

Dari hasil analisis fitur numerik ('age', 'fnlwgt', 'education-num', 'capital-gain', 'capital-loss', 'hours-per-week') dengan Histogram, Boxplot, Pairplot, dan Correlation Matrix Heatmap ditemukan:

- 1) Berdasarkan Histogram, Boxplot, dan Pairplot seluruh fitur numerik tidak berdistribusi normal.
- 2) Fitur hours-per-week terlihat memiliki jumlah *outlier* terbanyak, dengan *outlier* terjauh adalah 99 hours/week.
- 3) Fitur yang memiliki korelasi tertinggi dengan target income adalah education-num dengan $r = 0.34$.
- 4) Tidak ditemukan korelasi tinggi antar fitur independen yang artinya tidak adanya masalah multikolinearitas pada dataset.






1.4. Analisis fitur Kategorikal

Dari hasil analisis fitur kategorikal ('workclass', 'education', 'marital-status', 'occupation', 'relationship', 'race', 'sex', 'native-country') ditemukan:

- 1) Data yang dikumpulkan paling banyak berasal dari native-country united states (> 25000) dan workclass private (> 20000).
- 2) Status pernikahan Married-civ-spouse menjadi indikator terkuat dari sisi kategorikal yang membedakan kelas pendapatan >50K dan <=50K.



2. Preprocessing

2.1. Handling Missing Values

Pada tahap EDA ditemukan dua jenis missing values, yaitu NaN/Null dan karakter '?' pada fitur workclass, occupation, dan native-country. Langkah pembersihan yang dilakukan adalah mengonversi seluruh karakter '?' menjadi NaN terlebih dahulu, lalu menghapus seluruh baris yang mengandung data kosong tersebut. Ukuran data sebelum penghapusan baris dengan *missing value* adalah 39073 baris dan 15 kolom, sedangkan ukuran data setelah dilakukan penghapusan baris adalah 36183 baris dan 15 kolom.

Keputusan menghapus *missing value* dilakukan karena Proporsi nilainya pada setiap kolom relatif kecil, sehingga risiko kehilangan informasi akibat penghapusan baris jauh lebih rendah dibandingkan risiko bias yang dapat timbul.

```
df = df[df != '?']
df.dropna(inplace=True)
```

2.2. Standarisasi Variabel Target

Pada tahap EDA juga ditemukan bahwa kolom income memiliki inkonsistensi pada penulisan datanya sehingga perlu dilakukan standarisasi. Standarisasi yang dilakukan adalah mengganti '<=50K' dan '<=50K.' Menjadi 0, dan mengganti '>50K' dan '>50K.' Menjadi 1.

```
df['income'] = df['income'].replace({'>50K': 1, '>50K.': 1, '<=50K': 0, '<=50K.': 0})
```

Hasil standarisasi:

- 0: 27216 baris
- 1: 8967 baris

2.3. Encoding Fitur Kategorikal

Agar fitur kategorikal dapat dipahami oleh Machine Learning, fitur kategorikal harus diubah menjadi bentuk numerik. Di sini digunakan teknik One-Hot Encoding. Fitur yang Di-encode Adalah workclass, education, marital-status, occupation, relationship, race, sex, dan native-country. Setelah fitur di-encode, Seluruh nilai *boolean* (True/False) hasil dari One-Hot Encoding dikonversi menjadi integer (1/0). Hasil dari proses ini merubah dimensi data dari 15 kolom jadi 97 kolom.

```
print(df.shape)
df_encoded = pd.get_dummies(df, columns=['workclass', 'education', 'marital-status', 'occupation', 'relationship', 'race', 'sex',
                                         'native-country'], drop_first=True)
print(df_encoded.shape)
df_encoded.head(10)
```

2.4. Train-Test Split

Train-test split harus dilakukan sebelum proses scaling untuk mencegah data leakage dari data testing ke data training. Rasio split yang digunakan Adalah 80% data training dan 20% data testing. Hasil dari data split adalah data training 28946 baris dan 96 kolom, sedangkan data testing 7237 baris dan 96 kolom.

```
x = df_encoded.drop('income', axis=1)
y = df_encoded['income']

x_train, x_test, y_train, y_test = train_test_split(x, y, test_size=0.2, random_state=42, stratify=y)
```

Penting juga untuk memastikan distribusi data training dan data testing mirip.

```
Data distribution in training set: income
0    0.752159
1    0.247841
Name: proportion, dtype: float64
Data distribution in testing set: income
0    0.752245
1    0.247755
Name: proportion, dtype: float64
```

2.5. Scaling Fitur Numerik

Fitur-fitur numerik (age, fnlwgt, education-num, capital-gain, capital-loss, dan hours-per-week) memiliki rentang skala nilai yang sangat bervariasi. Oleh karena itu, digunakan `StandardScaler` untuk mentransformasikan data numerik agar memiliki rata-rata = 0 dan varians = 1. Scaler difit hanya pada `x_train`, kemudian objek scaler yang sama digunakan kembali pada *validation split* maupun `test.csv` untuk mencegah *data leakage*.

```
scaler = StandardScaler()
x_train[num_cols] = scaler.fit_transform(x_train[num_cols])
x_test[num_cols] = scaler.transform(x_test[num_cols])
```

3. Pengembangan dan Eksperimen Model Machine Learning

3.1. Multi-Feature Logistic Regression

Model Logistic Regression dipilih sebagai baseline karena paling sederhana dan cepat dilatih. Jika model yang lebih kompleks tidak lebih unggul dari model ini, maka kompleksitas tambahan tidak dibutuhkan untuk data ini.

```
model_multi = LogisticRegression()
model_multi.fit(x_train, y_train)
y_pred_multi = model_multi.predict(x_test)
```

3.2. Random Forest Classifier

Model ini dipilih untuk menguji apakah model non-linear bisa menangkap pola yang tidak terlihat oleh model Logistic Regression.

```
model_rf = RandomForestClassifier(n_estimators=100, class_weight='balanced', random_state=42)
model_rf.fit(x_train, y_train)
y_pred_rf = model_rf.predict(x_test)
```

3.3. XGBoost Classifier

Model ini dipilih karena setiap pohon baru dilatih secara bertahap untuk memperbaiki kesalahan prediksi dari pohon-pohon sebelumnya, membuat model ini lebih sensitif terhadap pola-pola kecil yang mungkin terlewat oleh model lain. Hal ini akan bermanfaat untuk menangkap pola kelas minoritas (“>50K”) yang jumlahnya lebih sedikit.

```
scale_pos_weight = (y_train == 0).sum() / (y_train == 1).sum()

model_xgb = XGBClassifier(
    n_estimators=400,
    max_depth=8,
    learning_rate=0.1,
    scale_pos_weight=scale_pos_weight,
    random_state=42,
    eval_metric='logloss',
    n_jobs=-1
)

model_xgb.fit(x_train, y_train)
y_pred_xgb = model_xgb.predict(x_test)
```

4. Evaluasi model

4.1. Multi-Feature Logistic Regression

Sebagai model *baseline*, regresi logistik ini memberikan performa awal yang cukup baik:

- 1) Akurasi sebesar 85% dengan F1-Score Macro di angka 0.7855.
- 2) Pada Classification Report, recall untuk kelas 0 sangat baik (0.93), sedangkan recall untuk kelas 1 hanya 0.61.
- 3) Model sangat baik mengenali mayoritas kelas pendapatan $\leq 50K$ dengan 5.069 True Negatives. Namun, model cukup sulit menebak kelas $> 50K$, terbukti dari tingginya False Negatives yang mencapai 707 sampel.
- 4) Kemampuan model memisahkan probabilitas dua kelas sudah cukup baik dengan ROC AUC 0.91 dan Precision-Recall Average Precision (AP) sebesar 0.77.


```
Classification Report for Multi-feature Logistic Regression Model:
              precision    recall  f1-score   support

      0       0.88        0.93        0.90        5444
      1       0.74        0.61        0.67        1793

   accuracy                0.85        7237
  macro avg       0.81        0.77        0.79        7237
weighted avg       0.84        0.85        0.85        7237

F1 Score for Multi-feature Logistic Regression Model: 0.7855
```

Evaluation: Logistic Regression (Multi Feature)



4.2. Random Forest Classifier

Model Forest Classifier memiliki hasil yang hampir mirip dengan model Logistic Regression:

- 1) Akurasi sebesar 85% dengan F1-Score Macro di angka 0.7873, sedikit lebih baik dari logistic Regression.
- 2) Classification Report sama persis dengan model sebelumnya, recall untuk kelas 0 adalah 0.93, sedangkan recall untuk kelas 1 hanya 0.61.
- 3) Model ini lebih baik dalam menebak kelas $> 50K$ dibandingkan model sebelumnya, dengan True Positives naik menjadi 1102. Hal ini diikuti dengan penurunan tipis pada False Negatives menjadi 691.
- 4) Kemampuan model memisahkan probabilitas dua kelas jadi sedikit melandai. Nilai ROC AUC turun menjadi 0.90 dan PR AP menyusut ke 0.76.

```


Classification Report for Random Forest Model:
              precision    recall  f1-score   support

     0               0.88       0.93       0.90       5444
     1               0.74       0.61       0.67       1793

 accuracy               0.85       0.85       0.85       7237
 macro avg              0.81       0.77       0.79       7237
 weighted avg           0.84       0.85       0.85       7237

F1 Score for Random Forest Model: 0.7873
  
```

Evaluation: Random Forest Classifier



4.3. XGBoost Classifier


Model XGBoost Classifier menunjukkan hasil yang terbaik diantara dua model lainnya:

- 1) Akurasi sebesar 84% dengan F1-Score Macro terbesar di angka 0.8049.
- 2) Di Classification Report recall untuk kelas 1 naik drastis jadi 0.83, sedangkan recall untuk kelas 0 adalah 0.84.
- 3) Di model ini, True Positives melompat tajam ke angka 1.487, dan model hanya 306 data di False Negatives.
- 4) Kemampuan model memisahkan probabilitas sangat baik dengan skor ROC AUC 0.92 dan Precision-Recall AP setinggi 0.82.

Classification Report for XGBoost Model:

	precision	recall	f1-score	support
<=50K	0.94	0.84	0.89	5444
>50K	0.64	0.83	0.72	1793
accuracy			0.84	7237
macro avg	0.79	0.84	0.80	7237
weighted avg	0.86	0.84	0.85	7237

F1 Score for XGBoost Model: 0.8049



5. Kesimpulan

Dari tiga algoritma yang diuji, XGBoost Classifier terpilih sebagai model terbaik (Champion Model) karena berhasil mengatasi masalah ketimpangan kelas secara signifikan dengan melonjakkan recall kelas minoritas (>50K) hingga 0.83 dan memangkas False Negatives menjadi tersisa 306 sampel, sehingga menghasilkan F1-Score Macro tertinggi sebesar 0.8049 serta daya pisah probabilitas superior (ROC AUC = 0.92 dan Precision-Recall AP = 0.82) yang siap digunakan untuk inferensi akhir pada dataset uji.

Deklarasi Penggunaan AI

AI Tools: Gemini 3.6 Flash dan Claude Sonnet 5 (Gemini, Claude, Agustus 2026): diunakan untuk merangkum soal, eksplorasi referensi, penulisan syntax dan debugging, saran perbaikan, perangkaian kata, koreksi tata Bahasa. Penggunaan AI hanya digunakan sebagai alat bantu teknis. Logika, analisis, validasi data, dan isi laporan sepenuhnya divalidasi serta menjadi tanggung jawab penulis.